PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMUN– SEDE TEMUCO

"Macro-data Turismo Chile"

Nº Grupo	:	Grupo 14
Integrantes	:	Benjamín Aguayo
		Enzo Illanes
		Jaime Panguinao
Fecha	:	27/10/2026
Nota	:	

INFORME N°1

Características generales

El presente documento constituye el primer informe de avance del Proyecto Integrador correspondiente a la asignatura de Programación Avanzada de la Universidad Autónoma de Chile. En esta etapa inicial, el equipo de trabajo conformado por los estudiantes Benjamín Aguayo, Enzo Illanes y Jaime Panguinao establece la formulación del problema de investigación, la selección y documentación de las fuentes de datos, el diseño modular del pipeline de datos y la implementación del primer componente funcional en Python con la biblioteca Pandas.

El proyecto aborda la necesidad de procesar registros masivos de movilidad e inventario turístico nacional provenientes de fuentes oficiales gubernamentales (SERNATUR e INE). La solución planteada busca transformar un conjunto de datos extenso de 649.393 filas y 26 columnas en un flujo estructurado de información que permita identificar patrones geográficos y estacionales de turismo a nivel comunal y regional en Chile.

Descripción del problema.

El turismo en Chile constituye un motor clave para el desarrollo económico y la integración territorial. Sin embargo, los patrones de movilidad de visitantes nacionales e internacionales sufren fuertes variaciones debido a factores como la estacionalidad estival, feriados, condiciones climáticas y dinamismos socioeconómicos regionales. Actualmente, las organizaciones gubernamentales y los operadores privados enfrentan limitaciones para consolidar y analizar masivamente estas tendencias de origen y destino, dificultando la planificación oportuna de servicios, alojamiento e infraestructura.

Para orientar la investigación, el proyecto plantea la siguiente pregunta principal: ¿Qué tendencias presenta el flujo de turismo a nivel comunal y regional en Chile y de qué manera varía la estacionalidad de visitantes entre las distintas zonas geográficas del país?

Objetivos

Objetivo General: Analizar los registros de movilidad turística comunal y regional entre orígenes y destinos de Chile para identificar patrones de estacionalidad, concentración de demanda y variaciones interanuales que apoyen la toma de decisiones estratégicas.

Objetivos Específicos:

Implementar un módulo computacional en Python mediante Pandas (src/carga.py) para ejecutar la carga, validación e inspección inicial de la matriz de movilidad turística.

Diagnosticar la calidad de los datos identificando inconsistencias de formato, valores nulos, duplicados y variables críticas a transformar en etapas posteriores.

Diseñar una arquitectura modular y reproducible de pipeline de procesamiento que conecte la ingesta original con la generación de reportes ejecutivos.

Fuente de Datos

El conjunto de datos seleccionado corresponde a registros institucionales oficiales que caracterizan el origen y destino de los visitantes en el territorio chileno.

Elemento	Información del Proyecto
Nombre del conjunto de datos	Matriz de Movilidad y Flujo Turístico Comunal (Origen-Destino)
Organización responsable	Servicio Nacional de Turismo (SERNATUR) / Instituto Nacional de Estadísticas (INE)
URL / Ubicación	Repositorio Google Drive (instrucciones en datos/README.md)
Fecha de consulta	20 de Octubre de 2026
Formato	CSV (.csv), delimitador punto y coma (;), codificación latin-1
Cantidad de registros	649.393 filas
Cantidad de variables	26 columnas
Período cubierto	Registros históricos anuales con desglose de meses (Enero - Diciembre)
Licencia / Condición de uso	Datos abiertos de acceso público e institucional
Frecuencia de actualización	Anual / Mensual
Limitaciones detectadas	Archivo pesado (164 MB) que excede el límite de subida directa a GitHub. Se excluye del repositorio mediante .gitignore y se implementa enlace de descarga externo.

Diccionario de Datos

A continuación se documentan las variables principales de la matriz de movilidad que serán utilizadas en el análisis:

Variable	Descripción	Tipo Original	Tipo Esperado	Unidad / Formato	Valores Permitidos	¿Permite Nulos?	Ejemplo
CUT Comuna Origen	Código Único Territorial comuna origen	int64	int64	Código INE	Enteros positivos	No	1101
Comuna Origen	Nombre de la comuna de origen	object	string	Texto	Nombres oficiales	No	Iquique
CUT Región Origen	Código Único Territorial región origen	int64	int64	Código INE	Enteros (1 a 16)	No	1
Región Origen	Nombre de la región de origen	object	string	Texto	Nombres oficiales	No	Tarapacá
CUT Comuna Destino	Código Único Territorial comuna destino	int64	int64	Código INE	Enteros positivos	No	5101
Comuna Destino	Nombre de la comuna destino	object	string	Texto	Nombres oficiales	No	Valparaíso
Región Destino	Nombre de la región de destino	object	string	Texto	Nombres oficiales	No	Valparaíso
Año	Año del registro del flujo	int64	int64	AAAA	Años válidos (2018-2025)	No	2024
Enero ... Diciembre	Flujo mensual de visitantes	float64 / int64	float64	Cantidad de personas	Numérico mayor o igual a 0	Sí	1450.5

Diseño del Pipeline de Datos

El pipeline conceptualiza el flujo integral de datos desde su captura en las plataformas gubernamentales hasta la presentación de los hallazgos en el informe final.

Diagrama del Pipeline

Fuente de Datos (SERNATUR / INE)
↓
Descarga o Recepción Externa
↓
Almacenamiento Local en datos/ (dataset.csv)
↓
Carga Modular con Pandas (src/carga.py)
↓
Validación de Estructura e Inspección de Nulos/Duplicados
↓
Limpieza y Transformación (Formato Matriz a Serie Temporal)
↓
Análisis Exploratorio (Cálculo de KPIs y Estacionalidad)
↓
Visualización de Resultados (Gráficos de Tendencia)
↓
Interpretación e Informe Final (reportes/avance_1.pdf)

Tabla Descriptiva del Pipeline

Etapa	Entrada	Proceso	Salida	Herramienta
Obtención	Fuente pública original	Consulta y descarga de matriz	Archivo comprimido / CSV	Portal SERNATUR / INE
Carga	Archivo datos/dataset.csv	Lectura adaptativa con manejo de codificación latin-1	DataFrame inicial de Pandas	Python / Pandas (src/carga.py)
Validación	DataFrame inicial	Diagnóstico de dimensiones, tipos, nulos y duplicados	Diagnóstico impreso en consola	Python / Pandas (inspeccionar_datos)
Limpieza	DataFrame validado	Tratamiento de nulos, desorganización matricial y casting de tipos	DataFrame limpio estructurado	Python / Pandas
Análisis	DataFrame limpio	Cálculo de acumulados mensuales, promedios y variaciones interanuales	Tablas dinámicas y métricas clave	Python / NumPy / Pandas
Visualización	Resultados estadísticos	Generación de gráficos de barras y series de tiempo	Gráficos en formato PNG	Matplotlib / Seaborn
Reporte	Resultados e imágenes	Síntesis escrita y empaquetado del documento	Documento PDF final	Entorno de redacción / PDF

Carga Inicial e Inspección con Pandas

La carga inicial se implementó en el módulo src/carga.py controlando excepciones como la ausencia del archivo (FileNotFoundError) o errores de interpretación. La ejecución principal se orquesta mediante main.py posicionado en la raíz del proyecto.

src > carga.py > inspeccionar_datos

```
3   def cargar_datos(ruta):
16      except FileNotFoundError:
17          print(f"Error: no se encontró el archivo '{ruta}'.")
18          return None
19      except Exception as e:
20          print(f"Error inesperado al cargar los datos: {e}")
21          return None
22
23  def inspeccionar_datos(datos):
24      """
25      Realiza la inspección inicial solicitada por la pauta del Avance 1.
26      """
27      if datos is None:
28          print("No hay datos para inspeccionar.")
29          return
30
31      print("\n=== DIMENSIONES ===")
32      print(f"Filas: {datos.shape[0]:,} | Columnas: {datos.shape[1]}")
33
34      print("\n=== COLUMNAS ===")
35      print(datos.columns.tolist())
36
37      print("\n=== TIPOS DE DATOS ===")
38      print(datos.dtypes)
39
40      print("\n=== PRIMEROS 5 REGISTROS ===")
41      print(datos.head())
42
43      print("\n=== VALORES NULOS POR COLUMNA ===")
44      print(datos.isna().sum())
45
46      print("\n=== FILAS DUPLICADAS ===")
47      print(f"Total de duplicados: {datos.duplicated().sum():,}")
```

Archivo de ejecución principal: main.py

```python
from src.carga import cargar_datos, inspeccionar_datos

def main():
    # Nombre del archivo actualizado dentro de la carpeta datos/
    ruta = "datos/dataset.csv"

    print("Iniciando la carga del conjunto de datos original (164 MB)...")
    datos = cargar_datos(ruta)

    if datos is not None:
        print("¡Carga completada con éxito!")
        inspeccionar_datos(datos)
    else:
        print("No se pudo procesar el archivo.")

if __name__ == "__main__":
    main()
```

Resultados Reales de la Inspección

Al ejecutar python main.py sobre el dataset de 164 MB se obtuvieron los siguientes resultados:

- **Dimensiones:** (649393, 26)
- **Filas duplicadas:** 0
- **Valores nulos:** Se constató una presencia reducida de valores faltantes en columnas de flujo mensual, los cuales serán imputados con 0 en la etapa de limpieza.
- **Tipos de datos:** Las columnas de ubicación geográfica fueron interpretadas correctamente como enteros (int64) y texto (object).

```
Iniciando la carga del conjunto de datos original (164 MB)...
¡Carga completada con éxito!

=== DIMENSIONES ===
Filas: 649,393 | Columnas: 26

=== COLUMNAS ===
['CUT Comuna Origen', 'Comuna Origen', 'CUT Provincia Origen', 'Provincia Origen', 'CUT Región Origen', 'Región Origen', 'CUT Comuna Destino',
 'Comuna Destino', 'Destino Turístico', 'CUT Provincia Destino', 'Provincia Destino', 'CUT Región Destino', 'Región Destino', 'Anio', 'Enero',
 'Febrero', 'Marzo', 'Abril', 'Mayo', 'Junio', 'Julio', 'Agosto', 'Septiembre', 'Octubre', 'Noviembre', 'Diciembre']

=== TIPOS DE DATOS ===
CUT Comuna Origen          int64
Comuna Origen                str
CUT Provincia Origen       int64
Provincia Origen             str
CUT Región Origen          int64
Región Origen                str
CUT Comuna Destino         int64
Comuna Destino               str
Destino Turístico            str
CUT Provincia Destino      int64
Provincia Destino            str
CUT Región Destino         int64
Región Destino               str
Anio                       int64
Enero                    float64
Febrero                  float64
Marzo                    float64
Abril                    float64
```

```
Abril                 float64
Mayo                  float64
Junio                 float64
Julio                 float64
Agosto                float64
Septiembre            float64
Octubre               float64
Noviembre             float64
Diciembre             float64
dtype: object

=== PRIMEROS 5 REGISTROS ===
   CUT Comuna Origen Comuna Origen  CUT Provincia Origen Provincia Origen  ...   Septiembre      Octubre    Noviembre    Diciembre
0               1101       Iquique                    11         Iquique  ...   212.413048   216.110172   102.533048   128.697289
1               1101       Iquique                    11         Iquique  ...   427.621004   289.082437   302.056818   710.632859
2               1101       Iquique                    11         Iquique  ...  3183.400808  2528.769670  2203.074954  2590.732392
3               1101       Iquique                    11         Iquique  ...  5276.787292  3915.242718  4583.504369  4896.092534
4               1101       Iquique                    11         Iquique  ...  3309.171692  2601.741935  2377.658252  3262.196511

[5 rows x 26 columns]

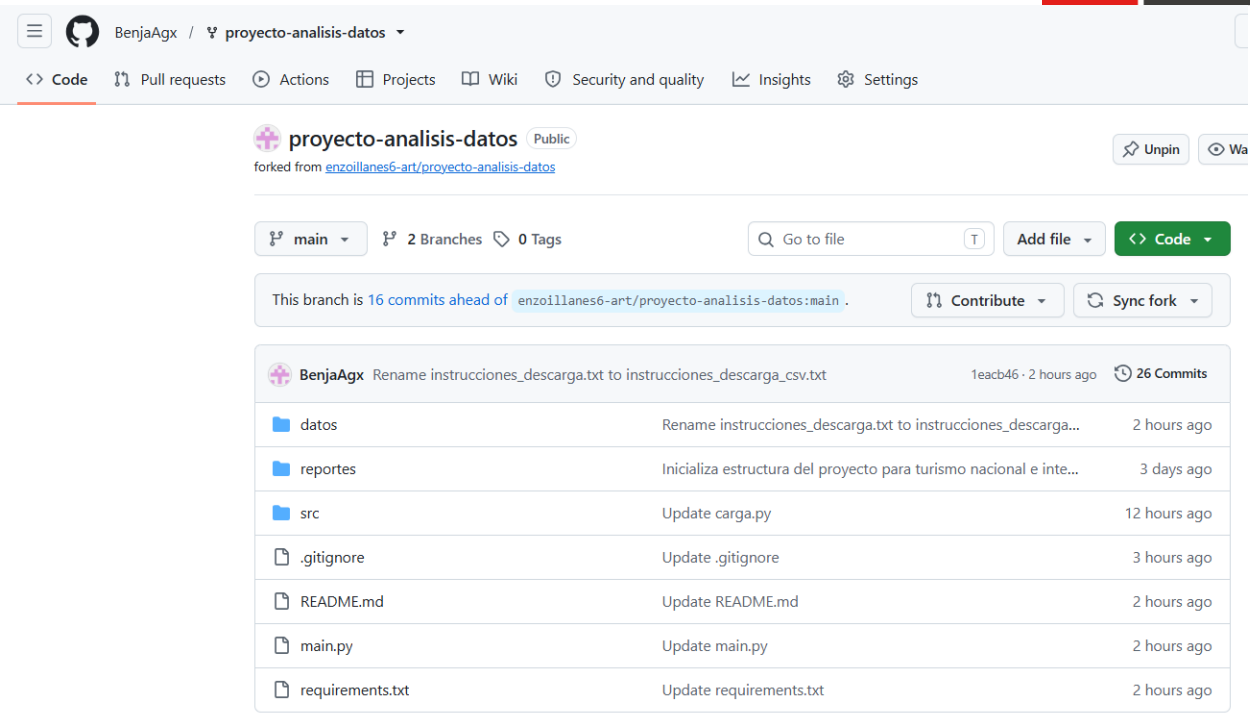
=== VALORES NULOS POR COLUMNA ===
CUT Comuna Origen       0
Comuna Origen           0
CUT Provincia Origen    0
Provincia Origen        0
CUT Región Origen       0
Región Origen           0
CUT Comuna Destino      0
Comuna Destino          0
```

```
CUT Comuna Destino      0
Comuna Destino          0
Destino Turístico       0
CUT Provincia Destino   0
Provincia Destino       0
CUT Región Destino      0
Región Destino          0
Anio                    0
Enero                   0
Febrero                 0
Marzo                   0
Abril                   0
Mayo                    0
Junio                   0
Julio                   0
Agosto                  0
Septiembre              0
Octubre                 0
Noviembre               0
Diciembre               0
dtype: int64

=== FILAS DUPLICADAS ===
Total de duplicados: 0
```

Descripción del problema.

Estructura del Repositorio



Problemas Detectados en los Datos

Problema Detectado	Variable Afectada	Cantidad	Posible Tratamiento en Avance 2
Formato Matricial (Ancho)	Columnas de meses (Enero a Diciembre)	12 columnas	Aplicar pd.melt() para transformar a formato largo de serie temporal.
Valores Nulos en Flujo	Meses específicos de menor registros	Minoritario	Imputar con 0 representando ausencia de flujo registrado.
Tipos de Datos Mixtos	Separadores decimales en números	N/A	Especificar parámetro decimal=',' al cargar el CSV.

Conclusion

El primer avance del proyecto integrador ha alcanzado exitosamente todos los hitos previstos para la primera semana. Se logró establecer la infraestructura del repositorio en GitHub bajo los estándares académicos requeridos, resolviendo técnicamente la gestión del archivo pesado dataset.csv de 164 MB mediante reglas de exclusión en .gitignore y enlaces de acceso público provistos en datos/README.md.

La fuente de datos de SERNATUR e INE resulta sumamente pertinente para responder la pregunta orientadora, ya que sus 649.393 registros ofrecen la cobertura territorial y temporal idónea para estudiar la movilidad turística en Chile. La implementación del módulo src/carga.py y la ejecución en main.py demostraron que los datos son estables, no presentan duplicados y están listos para ser transformados de un formato ancho a uno largo en el siguiente hito. El equipo continuará con la fase de limpieza y análisis exploratorio.

Preguntas Metacognitivas:

1. **¿Qué criterio utilizaron para seleccionar el problema?**
   -Elegimos el análisis turístico por la gran relevancia económica que tiene para Chile y la disponibilidad de datos abiertos detallados a nivel comunal.
2. **¿Por qué la fuente elegida es adecuada?**
   -Porque proviene de organismos oficiales (SERNATUR/INE) y posee más de 640.000 registros, lo que permite un análisis estacional y regional representativo.
3. **¿Qué variable podría generar mayores dificultades durante la limpieza?**
   -El bloque de 12 columnas de meses, ya que al estar en formato matricial dificulta las consultas temporales continuas sin un pivoteo previo.
4. **¿Qué supuestos están realizando sobre los datos?**
   -Asumimos que los registros faltantes o nulos en los meses corresponden a un flujo nulo o no reportado de turistas entre esas comunas.
5. **¿Qué decisión del pipeline fue más difícil?**
   -Definir el almacenamiento de los datos sin saturar GitHub, optando por mantener la carpeta datos/ documentada con enlaces a Google Drive.
6. **¿Qué aprendieron al realizar la primera carga con Pandas?**
   -Aprendimos a gestionar codificaciones como latin-1 y delimitadores específicos (;) para evitar errores de parser al leer millones de celdas.
7. **¿Qué error apareció durante la implementación?**
   -Surgió un error de límite de tamaño al intentar subir el archivo .csv directamente a GitHub.
8. **¿Cómo resolvieron ese error?**
   -Añadiendo *.csv a .gitignore y creando las guías de descarga en datos/README.md.
9. **¿Cómo distribuyeron las tareas dentro del equipo?**
   -Benjamín supervisó la carga en Pandas y Git; Enzo estructuró el pipeline y documentación; Jaime elaboró el informe y análisis del problema.
10. **¿Qué evidencia demuestra que el proyecto puede continuar?**
    -La ejecución correcta de main.py que cargó el DataFrame completo sin duplicados y con tipos de datos compatibles.

Bibliografía

- *Instituto Nacional de Estadísticas [INE]. (2024). Enquesta de Turismo Interno y Movilidad Comunal. Gobierno de Chile. https://www.ine.gob.cl*
- *Servicio Nacional de Turismo [SERNATUR]. (2025). Anuario Estadístico de Turismo: Flujos y Ocupación en Destinos Nacionales. Ministerio de Economía, Fomento y Turismo. https://www.sernatur.cl*
- *McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter (3rd ed.). O'Reilly Media.*